Universidad Nacional Autónoma de México

Facultad de Ciencias

Ingeniería de Software

Profesora:

- ★ Jessica Santizo Galicia

Ayudantes:

- ★ Diego Antonio Villalba Gónzalez
- ★ Ares Gael Castro Romero

Integrantes :

- ★ Cano Tenorio Alan Kevin
- ★ Gomez Calva Carlos Manuel
- ★ Lechuga Hervert Maximiliano
- ★ Vázquez Rincón Oscar

I. Conceptos

1. Da un ejemplo de Almacén de Datos (de acuerdo con tus intereses, no repetir lo visto en clase) y explica cómo se cumple la definición en tu ejemplo. Incluye:

- Orientación a temas
- Integración de datos
- Variabilidad en el tiempo
- No volatilidad

Ejemplo:

Un ejemplo de Almacén de Datos sería los datos que tiene la compañía de distribución de videojuegos para Computadora Steam que cumple con las siguientes definiciones:

Al tener una gran cantidad de datos, la forma en la que se orientan los temas serían los Jugadores(Clientes), Videojuegos(Productos), Empresas de videojuegos(Proveedores).

La integración de datos cae en la responsabilidad de la información de múltiples fuentes que en la forma que lidia Steam radicaría en la convención única, que seria los jugadores donde independiente a la región(continente) usa un mismo formato de para identificar a un jugador.

Son variables al tiempo porque existe un dato que es la cantidad de horas invertidas en un juego. En el caso de ver los datos de un videojuego, te muestra la cantidad de jugadores desde una cierta cantidad de tiempo atrás y se relaciona de manera directa que no sean volátiles dado que tienes el histórico del videojuego a pesar que hayan pasado 10 o 15 años desde su lanzamiento

2. Explica con tus propias palabras la diferencia entre un Almacén de Datos y:

- **Una base de datos transaccional**: Una base de datos transaccional está diseñada para realizar operaciones rápidas (por ejemplo: registros simples), permitiendo crear, leer, actualizar y borrar datos (CRUD) al instante. En cambio, un almacén de datos es utilizado para realizar un análisis masivo de datos, permitiendo insertar datos nuevos para ver cómo han cambiado las cosas a través del tiempo.

- **Un esquema estrella**: El esquema estrella es la estructura que se utiliza para organizar los datos que el almacén de datos contiene (separando los hechos de las dimensiones) para que las consultas sean mucho más rápidas y fáciles de entender.

- **Un cubo OLAP**: El Cubo OLAP es una estructura que toma datos desde un almacén de datos para que se puedan manipular de manera sencilla, por ejemplo, se pueden realizar filtros y cálculos rápidos (como ver ventas por día, estado y país) sin tener que procesar toda la base de datos de nuevo.

- **Un Data Lake**: El Data Lake es aquel que permite almacenar cualquier tipo de datos sin importar su formato. El Data Warehouse, por el contrario, solo acepta datos que ya pasaron por un proceso de limpieza y que encajan perfectamente en un esquema definido.

II. Escenario

El Instituto de Matemáticas de la Universidad Nacional Autónoma de México desarrolla y analiza modelos matemáticos mediante simulaciones numéricas, orientadas al estudio de ecuaciones diferenciales, sistemas dinámicos, procesos estocásticos y métodos numéricos.

Cada ejecución de simulación genera información distribuida que se encuentra en registros del clúster, bitácoras de ejecución, archivos de resultados y reportes de uso de recursos computacionales. Actualmente, esta información no está integrada, lo que dificulta el análisis histórico y la toma de decisiones estratégicas.

Por lo anterior, el Instituto te contrata para diseñar un Almacén de Datos que permita analizar el uso de recursos, el comportamiento de las simulaciones y su evolución a lo largo del tiempo.

III. Resuelve los siguientes ejercicios

1. Menciona qué beneficios tendrá utilizar un Almacén de Datos en un entorno de cómputo científico. Justifica.

   El principal beneficio es que permite juntar información que ahorita está regada por todos lados (clúster, logs y resultados) en un solo lugar. Esto se justifica porque facilita hacer análisis históricos que hoy son imposibles; por ejemplo, comparar si los modelos de hoy son más eficientes que los de hace dos años o ver exactamente cuánta RAM consumió una simulación específica sin tener que buscar en archivos de texto viejos. Además, asegura que todos los datos tengan el mismo formato, evitando errores al comparar resultados.

2. Indica qué usuarios utilizarían este Almacén de Datos y con qué propósito. Justifica.

   Los investigadores lo usarían para ver si sus algoritmos son eficientes, mientras que el staff técnico lo emplearía para monitorear el clúster y evitar que se sature. También serviría a los directivos para sacar estadísticas que justifiquen pedir más presupuesto a la UNAM y a los tesistas para comparar sus avances con estudios previos. Se justifica porque les da información ya procesada y lista para analizar según lo que cada quien necesite.

3. Escribe al menos cinco preguntas que el Instituto desearía responder en términos de análisis.
    a. ¿Cuánto consumo energético se produce en total por cada dia de simulación?
    b. ¿Cuál es el porcentaje de los resultados esperados?
    c. ¿Cuál es el porcentaje de los resultados no esperados?
    d. ¿Cuál es el recurso más usado durante las simulaciones?
    e. ¿Qué modelos matemáticos cumplen con los resultados esperados?
    f. ¿Cuánto tiempo se necesita en promedio para lograr analizar modelos matemáticos?

4. Describe qué datos históricos almacenaría el Data Warehouse del Instituto de Matemáticas y qué decisiones estratégicas apoyaría.
    a. Los datos históricos serían aquellos que tienen que ver con la cantidad de recursos/ tiempo utilizados en el análisis de modelos matemáticos. A su vez también sería guardar los resultados de la simulación
    b. Se apoya aquellas decisiones que permiten un buen flujo de seguimiento de datos de relevancia especialmente aquellos que permiten una mejora en el cómo se puede analizar modelos matemáticos de forma eficiente
5. Define el hecho principal del modelo multidimensional.
    a. El hecho principal sería EFICACIA

6. Explica qué representa una fila en la tabla de hechos y da cinco ejemplos.

Se consideran los siguientes niveles de granularidad para el hecho **Ejecución de Simulación**:

- Una fila por simulación científica
    - Representa la simulación donde tendría las veces que el modelo corrió en el cluster
- Una fila por ejecución completa de simulación
    - Representa una sola ejecución de un modelo desde que empieza hasta que termina

- Una fila por paso iterativo interno
    - Representa cada cálculo matemático dentro de los pasos iterativos

Los ejemplos serían los siguientes:

- Consumo de memoria
- Uso de CPU
- Conteo de pasos iterativos
- Tiempo de procesamiento
- Tamaño de la salida

7. Selecciona la granularidad adecuada y justifica por qué es preferible a las demás.

La granularidad que más nos sirve en este caso es tener una **alta granularidad** ya que como se realizarán simulaciones los cálculos junto con todas las variables involucradas necesariamente deben de estar ahí para hacer un buen análisis y no dejar ambigüedades porque cualquier mínimo detalle o número que se excluya puede cambiar su interpretación

8. Explica cuándo sería adecuada una granularidad alta y cuándo una baja, incluyendo sus ventajas y desventajas.

La **granularidad alta** nos permite tener mucha más información acerca del hecho que queremos registrar para poder hacer una análisis detallado y preciso, la desventaja de esto es que a cambio de poder mostrar con mayor precisión la información la cantidad de espacio que se necesita para almacenarla será mucho mayor, considero que es buena una alta granularidad cuando se almacenen datos de índole científico, estadísticos, económicos (como la bolsa de valores)

La **granularidad baja** es muy útil cuando el hecho que se requiere registrar no necesita de grandes cantidades de detalles para ser útil, solo contiene lo necesario para poder hacer un buen uso de esa información, considero que sirve para negocios no muy grandes, datos de ventas, algunos datos médicos

9. Dibuja el esquema estrella correspondiente al escenario. Considera que:

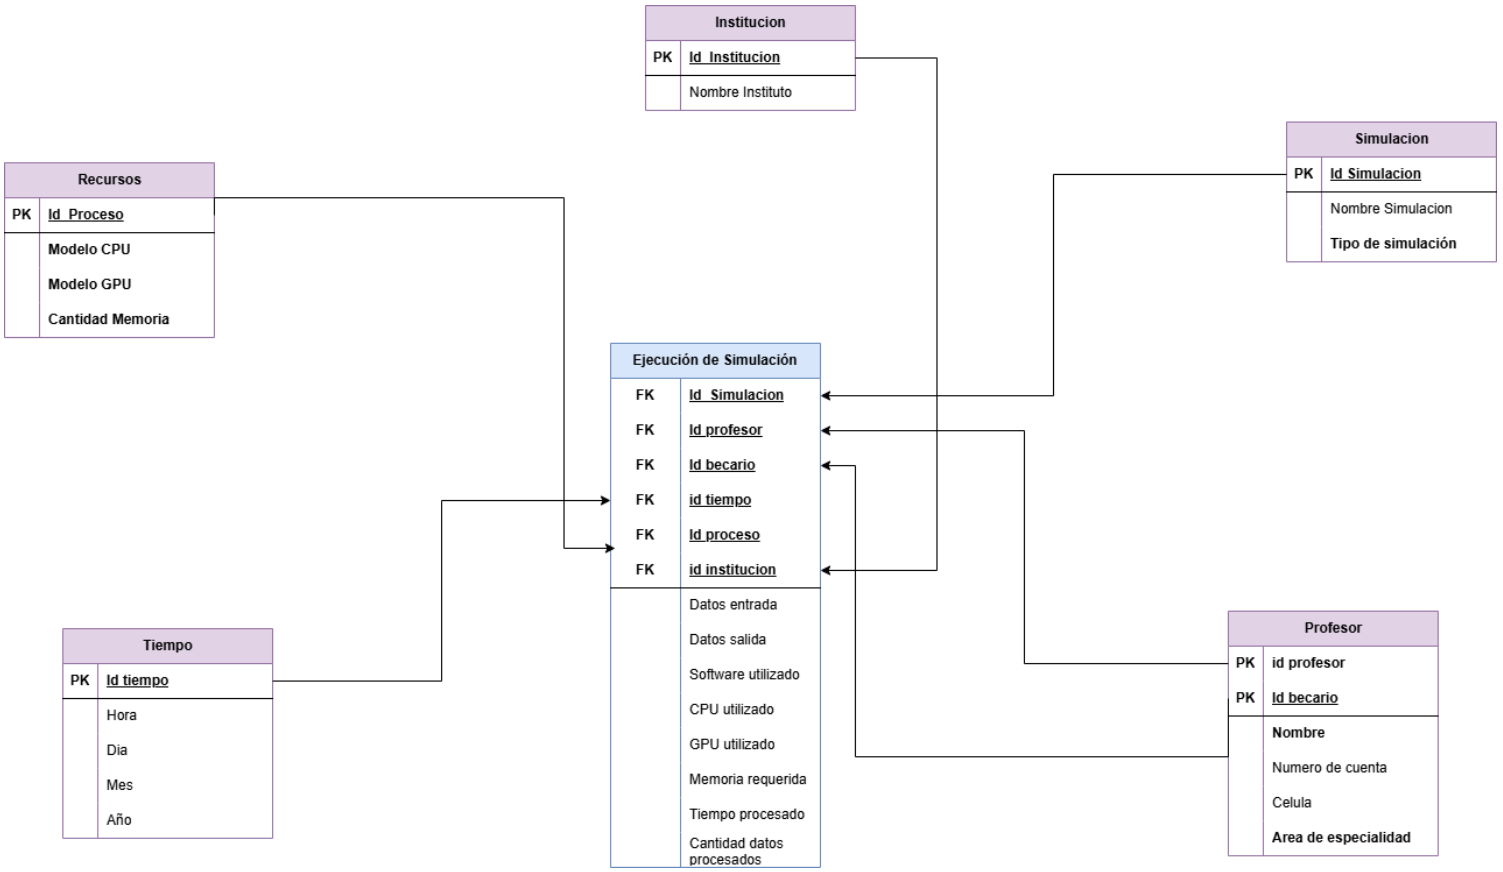

a) Debe haber al menos cuatro medidas numéricas.
b) Deben definirse al menos cinco dimensiones, incluidas Tiempo y Simulación.
c) Deben indicarse los atributos relevantes de cada dimensión.

10. Describe las capas de la arquitectura de un Almacén de Datos.

    Un almacén de datos se divide en 3 capas:

    1. **Data Source**: Se obtienen los datos de las fuentes externas (bases de datos, archivos de texto, entre otros) para detectar problemas de integración, diferencias de estructura y nivel de detalle para pasarlos a la siguiente capa.
    2. **Data Staging**: Se realiza un proceso ETL (Extract, Transform, Load), el cuál consiste en extraer los datos, luego realizar una limpieza de datos para eliminar datos corruptos y/o duplicados y se crea un formato de datos estándar para finalmente cargar los datos en el almacén.
    3. **Data Storage**: Los datos se encuentran limpios y son organizados por medio de un esquema (Star o Snowflake) para que se obtengan lo más rápido posible a la hora de realizar una consulta.

11. Explica el rol de cada capa en el contexto del cómputo científico.
    a. **Data Source**: Se obtienen todos los datos de las diferentes fuentes que se tengan (computadoras, experimentos, sensores, entre otros). Vienen en cantidades enormes debido a toda la información generada por segundo.
    b. **Data Staging**: Se normalizan todas las unidades de medida existentes (como los grados Celsius o Fahrenheit) y se eliminan datos erróneos generados por los instrumentos utilizados para que sea más preciso el análisis,
    c. **Data Storage**: Permite que los científicos analicen los datos obtenidos para detectar patrones, validar hipótesis o comparar resultados.

12. Indica dónde se implementa el modelo estrella.

    R: El modelo estrella se implementa en la capa de **Data Storage**, ya que, aquí es donde se realiza el diseño final del almacén de datos, además de que es necesario optimizar la consulta de los datos para obtener respuestas rápidas al separar los indicadores numéricos (hechos) de los contextos descriptivos (dimensiones).

IV. Detección de errores

Plantea y describe dos errores de diseño posibles en un Almacén de Datos para este escenario. Los errores no deben impedir la ejecución de consultas, pero sí producir resultados incorrectos o engañosos.

Problema 01: El error consiste en actualizar la información de un investigador (como su *Grado Académico* o el *Laboratorio* al que pertenece) directamente sobre el registro anterior

en la tabla de dimensiones. En un escenario científico, si un profesor pasa de "Candidato a Doctor" a "Doctor", y simplemente sobreescribimos el dato, todos los experimentos realizados en el pasado aparecerán como si los hubiera hecho ya siendo un"Doctor". Esto genera reportes engañosos sobre la productividad por los niveles académicos que a pasado.

- Un ejemplo de consulta donde el problema sea evidente. Si un investigador realizó 50 experimentos como "Maestro" y 10 como "Doctor", al sobrescribir su grado, la consulta dirá que hizo 60 experimentos como "Doctor". Esto altera las estadísticas históricas de rendimiento del Instituto lo cual también podría ser sospechoso.

- Cómo corregirías el error (ETL o modelo). Se corrige en el Modelo de Datos implementando una Dimensión de Cambio Lento (SCD) Tipo 2.

- Escribe detalladamente los pasos a seguir, así cómo tu solución.

1. Paso01: Rediseñamos la Tabla de Dimensión: Añadir tres columnas nuevas a la tabla `Dimension_Investigador`: `Fecha_Inicio`, `Fecha_Fin` y `Version_Actual`
2. Paso02: Modificamos el proceso ETL: En lugar de hacer un `UPDATE` al registro del investigador, el proceso debe de tener:
    - Cerrar el registro anterior poniendo una `Fecha_Fin` (la fecha de consulta).
    - Insertar una nueva fila con el nuevo grado académico, una nueva `Fecha_Inicio` y marcarla como la `Version_Actual`.
3. Paso 03: Vinculamos la Tabla de Hechos para Asegurarse de que la tabla use una "Clave Subrogada" (un ID numérico único por cada versión del investigador) en lugar de su número de empleado, para que cada experimento quede ligado permanentemente al grado que el científico tenía en ese momento exacto.

Problema 02: El error ocurre cuando se utiliza una sola columna de medida (por ejemplo, resultado_experimento) para guardar diferentes tipos de indicadores científicos como "Temperatura", "Presión" o "Humedad" dependiendo de una columna de tipo. En el diseño de un almacén de datos esto es un fallo grave porque no puedes sumar temperaturas con presiones; la columna se vuelve "no aditiva" y los cálculos pierden todo su sentido físico.

- Un ejemplo de consulta donde el problema sea evidente: Si intentamos sacar el total de resultados con una consulta como: SELECT SUM(resultado_experimento) FROM Hechos_Laboratorio;. El resultado será un número gigante sin ningún sentido, ya que la base de datos estará sumando grados Celsius con pascales de presión simplemente porque están amontonados en la misma columna numérica, lo que daría una cifra inútil para cualquier análisis científico.

- Cómo corregirías el error (ETL o modelo): Se corrige directamente en el Modelo de Datos reestructurando la tabla de hechos.

- Escribe detalladamente los pasos a seguir, así cómo tu solución.

1. Paso 01: Rediseñamos la Tabla de Hechos: En lugar de tener una columna genérica que acepte cualquier dato, creamos columnas específicas para cada métrica importante (ej. metrica_temperatura, metrica_presion, metrica_humedad).
2. Paso 02: Manejo de valores nulos: Configuramos el modelo para que, si un experimento solo mide temperatura, las columnas de presión o humedad queden en NULL o 0. Esto permite que las funciones de agregación como SUM o AVG operen únicamente sobre la columna correcta sin mezclar datos que no tienen nada que ver entre sí.
3. Paso 03: Ajuste del proceso ETL: Modificamos la carga de datos para que el sistema identifique el tipo de métrica que viene desde el sensor y la deposite exactamente en la columna que le corresponde, garantizando que cada indicador se mantenga separado y sea matemáticamente válido para futuras consultas.